CAHIER DES CHARGES

TECHNIQUE & FONCTIONNEL COMPLET

Plateforme Cognitive HealthTech — ClinAlert AI

Agents Autonomes (LLM) · RAG Sécurisé · Analytique Prédictive IoT · Scénario Clinique Complet · Plan de Sprints

Candidat	Abderrahim Boussyf
Établissement	EMSI Marrakech — Filière Data Science & IA
Entreprise	n.synergy
Encadrant entreprise	À compléter
Encadrant académique	À compléter
Durée du stage	4 mois — 2025/2026
Version	v3.0 — Édition Scénario Complet
Statut	CONFIDENTIEL — Usage interne

Table des Matières

0.	Résumé Exécutif	3
1.	Contexte & Problématique	4
2.	Périmètre Fonctionnel	5
3.	Scénario Clinique Complet — 24h + 21 Jours	7
4.	Architecture Technique — 3 Pipelines	16
5.	Sécurité, RGPD & Éthique IA	22
6.	Architecture Système & MLOps	25
7.	Plan de Sprints — 4 Mois	29
8.	Diagrammes d'Architecture	33
9.	Analyse & Gestion des Risques	36
10.	Critères de Succès & KPIs	38
11.	Livrables Attendus	40
12.	Validation & Signatures	41

0. Résumé Exécutif

> *ClinAlert AI transforme le cabinet médical en un système d'information proactif et augmenté. En 24 heures, la plateforme détecte une anomalie biométrique pendant le sommeil d'un patient, déclenche un triage cognitif en langage naturel, prédit son comportement vis-à-vis de son rendez-vous, synchronise le CRM du cabinet, et prépare une synthèse complète pour le médecin — économisant 11 minutes d'anamnèse par consultation.*

Ce document est le cahier des charges intégral de la plateforme. Il contient :

- Le scénario clinique complet — 12 actes sur 24h + 21 jours, avec les interfaces exactes de chaque acteur.
- L'architecture technique détaillée — 3 pipelines IA (IoT/LSTM, RAG/LLM, ML prédictif) + intégration Salesforce.
- Les diagrammes d'architecture — flux de données, composants système, pipeline MLOps.
- Le plan de sprints sur 4 mois — avec jalons, critères de succès, et livrables par sprint.
- La conformité réglementaire complète — RGPD Article 25, Loi 09-08 Maroc, AI Act européen.
- L'analyse des risques — 9 risques identifiés avec stratégies de mitigation.

Résultats Cibles à 4 Mois

F1-Score No-Show	AUC-ROC Anomalies	Latence RAG (P95)	Réduction No-Show
> 0.80	**> 0.85**	**< 150 ms**	**> 20 %**

1. Contexte & Problématique

1.1. Problèmes Identifiés dans l'Écosystème Médical

L'écosystème médical actuel souffre d'une digitalisation purement administrative. Les logiciels existants (Doctolib, dossiers papiers numérisés) ne tirent pas parti des données de santé disponibles. Trois problèmes structurels ont motivé ce projet :

#	Problème	Impact Opérationnel	Solution ClinAlert
1	Surcharge cognitive du praticien	10–15 min perdues par consultation sur l'anamnèse administrative. Fatigue décisionnelle accumulée.	Synthèse IA du DPA : symptômes + biométrie + historique en 1 page.
2	Absentéisme non contrôlé (no-show)	15–30% de créneaux vides = perte directe de revenus + désorganisation du planning.	Modèle XGBoost : prédiction de présence + rappels ciblés.
3	Médecine réactive	Les données SmartWatch existent mais ne sont jamais exploitées pour la prévention.	Pipeline LSTM IoT : détection d'anomalies nocturnes en temps réel.

1.2. Les Acteurs du Système

Karim Benali — Patient	42 ans, suivi pour hypertension. Porte une Samsung Galaxy Watch 6. Utilisateur de l'application mobile ClinAlert.
Dr. Nadia Fassi — Médecin	Cardiologue. Utilise le Dossier Patient Augmenté (DPA) sur tablette. Valide toutes les suggestions IA.
Fatima L. — Secrétaire	Gère l'agenda via Salesforce. Reçoit les tâches automatisées par le Trigger Apex. N'interagit jamais directement avec l'IA.
Système ClinAlert AI	3 agents autonomes orchestrés par FastAPI : Agent Navigation, Agent Triage Clinique, Agent Planification.

2. Périmètre Fonctionnel

2.1. Espace Patient Cognitif

2.1.1. Onboarding & Consentement Éclairé (RGPD Art. 7)

- Interface d'inscription avec consentement explicite et granulaire (opt-in séparé : données IoT / analyse NLP / partage médecin).
- Journalisation de chaque consentement : horodatage ISO 8601, version CGU, canal de collecte.
- Droits RGPD implémentés nativement : accès (Art. 15), rectification (Art. 16), effacement (Art. 17), portabilité (Art. 20).

2.1.2. Assistant de Triage Cognitif

- Dialogue en langage naturel (Darija / Français / Arabe) via LLM local Mistral 7B.
- Pré-tri basé sur la combinaison : symptômes déclarés + anomalies IoT de la nuit précédente.
- Disclaimer médical permanent et non désactivable affiché en haut de chaque écran.
- Escalade automatique vers prise de RDV urgent si score de risque dépasse le seuil calibré.

2.1.3. Synchronisation IoT

- Intégration optionnelle (opt-in) : Apple Health / Google Fit / API MQTT directe (BLE).
- Données collectées : fréquence cardiaque (bpm), SpO2 (%), HRV (ms), cycles de sommeil.
- Rétention maximale des données brutes : 30 jours. Au-delà, seules les features agrégées sont conservées.

2.2. Espace Praticien & Dashboard Décisionnel

2.2.1. Smart Agenda Prédictif

- Vue planning avec probabilité de no-show par créneau : code couleur vert (< 20%) / orange (20–40%) / rouge (> 40%).
- Proposition automatique de créneaux de remplacement lors d'une prédiction d'annulation.
- Historique des prédictions vs réalité pour évaluation continue du modèle.

2.2.2. Dossier Patient Augmenté (DPA)

- Synthèse IA auto-générée : symptômes déclarés (verbatim NLP) + anomalies IoT (graphe HRV/FC) + historique pertinent.
- Suggestions RAG (littérature médicale validée) présentées comme pistes — jamais comme diagnostics.
- Interface Human-in-the-Loop : le médecin valide / modifie / rejette chaque suggestion. Le rejet alimente le retraining.

2.2.3. Système d'Alertes Temps Réel

- Alertes push déclenchées par le pipeline LSTM lors d'anomalies sur 2 fenêtres consécutives (garde anti-faux positifs).

- Seuils d'alerte configurables par le praticien (aucune valeur fixe imposée).
- Mode dégradé : si pipeline IoT indisponible, bascule sur polling HTTPS toutes les 5 minutes.

2.3. Contraintes Système Non Fonctionnelles

Catégorie	Exigence	Valeur Cible
Performance	Latence API RAG (percentile 95)	< 150 ms
Performance	Temps réponse API REST (P95)	< 200 ms
Disponibilité	Uptime système global	> 99.5%
Sécurité	Chiffrement en transit	TLS 1.3 obligatoire
Sécurité	Chiffrement au repos	AES-256 (pg_crypto)
IoT	Latence ingestion Kafka → TimescaleDB	< 5 secondes
MLOps	Drift détecté avant dégradation F1 > 10%	Alerte Evidently AI
Résilience	Perte de données en cas de panne Kafka	0 (buffer local)

3. Scénario Clinique Complet — 24h + 21 Jours

Ce scénario est la démonstration vivante de l'architecture. Chaque acte correspond à un pipeline technique précis. Il sert de script de démonstration pour la soutenance PFE et de cahier de tests fonctionnels pour les sprints 5 à 8.

ACTE I 02h14 — **La Nuit Silencieuse — Détection IoT** — Pipeline : IoT · LSTM · TimescaleDB

Karim dort. Son corps travaille. Le pipeline IoT tourne en autonomie complète.

Flux technique détaillé :

1. La Samsung Galaxy Watch 6 de Karim transmet ses données biométriques toutes les 10 secondes via MQTT/BLE chiffré TLS 1.3.
2. Le broker Apache Kafka ingère le flux sur le topic patient_uuid_7e2f (UUID pseudonymisé — aucun lien avec l'identité civile).
3. TimescaleDB écrit les points dans la hypertable biometrics avec compression automatique activée.
4. Le modèle LSTM bidirectionnel analyse une fenêtre glissante de 30 minutes (180 points). À 02h14 : score MSE = 4.7, soit 3.2 déviations standard au-dessus de la référence de Karim.
5. Règle anti-faux positifs : le système attend 2 fenêtres consécutives anormales avant toute action. À 02h19, la deuxième fenêtre confirme (MSE = 4.2, > μ+3σ).
6. Un événement anomaly_detected est publié dans Kafka. L'agent autonome l'intercepte, écrit un enregistrement dans PostgreSQL, et programme une notification push pour 07h30 (heure de réveil calculée depuis l'historique d'activité de Karim).

Valeurs observées :

HRV nocturne	18ms — anormal (référence Karim : 28ms ± 4ms)
Fréquence cardiaque	72 bpm — normale
SpO2	96% — normale (minimum observé : 94%)
Score MSE LSTM	4.7 → 4.2 sur 2 fenêtres consécutives
Seuil d'alerte	μ + 3σ = 3.8 — les deux fenêtres dépassent ce seuil
Action déclenchée	Notification programmée pour 07h30 — tonalité non alarmiste

Pourquoi 07h30 et pas 02h19 ? Réveiller un patient à 2h du matin pour une anomalie non confirmée est une mauvaise pratique clinique. Le protocole prévoit de regrouper l'alerte à l'heure de réveil habituelle. Si l'anomalie avait été critique (SpO2 < 88% ou FC > 150), la notification aurait été immédiate.

ACTE II 07h31 — **Le Réveil de Karim — Notification Push** — Pipeline : Agent Autonome · FastAPI

Karim prend son café. Son téléphone vibre. L'application ClinAlert affiche la notification.

Contenu exact de la notification :

> *"Bonjour Karim, notre système a relevé une variation inhabituelle de vos constantes cette nuit. Souhaitez-vous évaluer vos symptômes avec notre assistant ?"*

Décisions de l'agent autonome :

- Tonalité non alarmiste : aucun mot 'urgent', 'danger', 'arythmie'. Protocole anti-anxiété.
- Aucun diagnostic dans la notification : le système invite au dialogue, pas à la panique.
- Deux options : Évaluer (ouvre le chatbot) / Plus tard (programme un nouveau rappel à 09h00).
- Si aucune réponse dans 2h → relance automatique avec SMS (canal de secours).

ACTE III 07h33 — Triage Cognitif — Chatbot RAG + LLM — Pipeline : NLP · RAG · Qdrant · Mistral 7B

Karim tape sur 'Évaluer'. L'application s'ouvre. L'Agent de Navigation transfère la session à l'Agent de Triage Clinique, qui a déjà chargé en mémoire (Redis) le contexte de l'anomalie IoT.

Conversation réelle (transcription NLP) :

Agent IA	Bonjour Karim. Cette nuit, entre 02h14 et 02h22, notre système a détecté une variabilité inhabituelle de votre fréquence cardiaque pendant votre sommeil. Pouvez-vous me dire comment vous vous sentez ce matin ?
Karim	Je me sens un peu essoufflé ce matin et j'ai mal à la tête. C'est peut-être juste que j'ai mal dormi ?
Système	*[Vectorisation de la requête → Qdrant interrogé sur 84 000 chunks médicaux → Re-ranking cross-encoder top-5 → Croisement contexte IoT → Génération Mistral 7B → Latence : 143ms]*
Agent IA	La combinaison de vos symptômes (essoufflement matinal, céphalée) avec les données biométriques de la nuit (variabilité HRV anormale) mérite une évaluation par le Dr. Fassi aujourd'hui. Ces éléments combinés ne sont pas alarmants en eux-mêmes, mais le Dr. Fassi préférerait vous voir rapidement. Souhaitez-vous prendre un rendez-vous aujourd'hui ? ⚠️ Disclaimer : ce système effectue un pré-tri et ne remplace pas un médecin.

Performance RAG mesurée :

Chunks interrogés	84 000 documents médicaux indexés dans Qdrant
Modèle d'embedding	multilingual-e5-large (768 dimensions)
Top-k initial	20 résultats → re-ranking cross-encoder → top-5
Latence totale	143ms — sous le seuil cible de 150ms
Score RAGAS	Faithfulness : 0.89 · Relevancy : 0.91
Sources RAG utilisées	HAS (Arythmie) + Guidelines ESC 2023 + Historique patient

ACTE IV 07h36 — Planification Intelligente — Modèle No-Show — Pipeline : XGBoost · FastAPI · Optimisation

Karim accepte de prendre un rendez-vous. En 340 millisecondes, le modèle XGBoost analyse son profil.

Features injectées dans le modèle :

Feature	Valeur — Karim	Impact SHAP
urgence_score (triage IA)	0.78 (élevé)	+0.31 (le plus fort)
historique_annulations_6m	2 annulations (vendredi)	-0.18
jour_semaine	Mardi	+0.12
meteo_temperature	24°C, ensoleillé	+0.08
delai_prise_rdv_heures	0.05h (immédiat)	+0.19
distance_cabinet_km	2.3 km	+0.07
type_consultation	Urgence relative	+0.14

Résultat de la prédiction :

Probabilité de no-show	15% — Risque FAIBLE
Justification	L'urgence perçue (score 0.78) compense l'historique d'annulations. SHAP urgence_score = +0.31.
Créneau proposé	14h30 — créneau intercalé, taux remplissage cabinet : 94%
Rappels automatiques	SMS J-1 + Push J-1 + SMS le matin même

ACTE V 07h36 + 340ms

Interopérabilité CRM — Salesforce Apex — Pipeline : REST API · Apex Trigger · CRM

Dès que Karim confirme le créneau, le backend FastAPI orchestre simultanément 3 actions en parallèle :

7. Écriture dans PostgreSQL (table appointments) avec tous les métadonnées.
8. Envoi SMS de confirmation à Karim via API SMS (Twilio ou équivalent).
9. Déclenchement du webhook Salesforce : payload JSON sécurisé vers l'API REST Salesforce.

Payload JSON envoyé à Salesforce :

```
{
  "patient_id": "uuid-7e2f-...",  // UUID pseudonymisé
  "patient_name": "Karim Benali",
  "rdv_datetime": "2025-06-18T14:30:00+01:00",
  "urgency_flag": "ANOMALIE_IOT_ESSOUFFLEMENT",
  "no_show_proba": 0.15,
  "rag_summary": "HRV anormale + dyspnée + céphalée. ECG recommandé.",
  "salle_requise": "ECG"
}
```

Ce que le Trigger Apex fait dans Salesforce :

10. Détecte le flag urgency_flag = ANOMALIE_IOT_ESSOUFFLEMENT.
11. Met à jour le Custom Object Fiche_Patient__c de Karim.
12. Crée une tâche prioritaire ROUGE sur le Dashboard Salesforce de Fatima : 'Patient urgent 14h30 — Préparer salle ECG'.
13. Colore le créneau en rouge dans l'agenda partagé.

Important : Fatima n'interagit jamais avec l'application IA. Elle travaille dans son CRM habituel (Salesforce). Toutes les informations convergent vers elle automatiquement. C'est le principe d'interopérabilité métier du CDC.

ACTE VI 14h30 **Consultation Augmentée — Dossier Patient Augmenté** — Pipeline : LLM · RAG · Human-in-the-Loop

Karim arrive. Le Dr. Fassi ouvre son dossier. Au lieu de 5 pages à lire, elle a accès à une synthèse structurée en 3 colonnes :

Données IoT — Nuit	Symptômes Déclarés — 07h34	Suggestions RAG — À Valider
HRV : 18ms ↓ (réf. 28ms) FC : 72 bpm SpO2 : 96% (min 94%) Anomaalie : 02h14–02h22 LSTM MSE : 4.7 (+3.2σ)	Verbatim : "Je me sens essoufflé et j'ai mal à la tête" Entités extraites : - Dyspnée légère - Céphalée - Fatigue perçue Pré-tri RAG : HRV↓ + dyspnée + céphalée → ECG recommandé	1. ECG 12 dérivations [PRIORITAIRE] 2. Mesure PA brachiale bilatérale 3. Vérifier observance IECA 4. Bilan NFS+iono si PA > 150 → Validation médecin requise

Mécanisme Human-in-the-Loop :

- Le Dr. Fassi valide les suggestions 1, 2, 3 (ECG + PA + observance IECA).
- Elle rejette la suggestion 4 (NFS systématique — jugée prématurée).
- Chaque action (valider/rejeter) est journalisée avec le raisonnement du médecin.
- Le rejet de la suggestion 4 est un point de données négatif envoyé à MLflow : ce pattern (extrasystolie légère sans PA > 150) ne nécessite pas de NFS immédiate.

Résultat opérationnel : Le Dr. Fassi a économisé 11 minutes d'anamnèse. Elle est allée directement à l'auscultation et l'ECG. L'ECG a révélé une extrasystolie ventriculaire bénigne — exactement le pattern détecté par le LSTM la nuit précédente.

ACTE VII 15h05 **Résultat Clinique & Feedback MLOps** — Pipeline : Human-in-the-Loop · MLflow · Retraining

Diagnostic posé par le Dr. Fassi : Extrasystolie ventriculaire bénigne. Ajustement de la dose d'IECA. Holter ambulatoire programmé dans 21 jours. Le DPA est mis à jour automatiquement. La validation du médecin alimente le pipeline d'apprentissage continu.

Ce que le système apprend de cette consultation :

- Le score urgence_score = 0.78 était un bon prédicteur de présence (Karim est venu). Feature renforcée dans XGBoost.

- La combinaison HRV < 20ms + dyspnée + antécédent HTA → ECG justifié. Pattern validé dans la base RAG.
- La suggestion 'NFS systématique' rejetée pour ce profil → score de pertinence abaissé dans ce contexte.
- Nouveau pattern enregistré : extrasystolie bénigne + IECA ajusté → suivi semestriel (pas mensuel).

ACTE VIII J+1 · 03h42

La Nuit Suivante — Garde Anti-Faux Positifs — Pipeline : LSTM · Mécanisme de Confirmation

Mme. Leila Oujda, 58 ans, diabétique. Le LSTM détecte une anomalie dans sa HRV à 03h42. Mais contrairement à Karim, le système ne déclenche rien.

Pourquoi ? Le mécanisme de confirmation à 2 fenêtres :

14. 03h42 : Fenêtre 1 anormale — MSE = 3.1 > μ+3σ. Système en attente.
15. 03h47 : Fenêtre 2 normale — MSE = 2.1 < seuil. Cause identifiée : mouvement brusque (accéléromètre détecte un retournement).
16. Alerte annulée. Événement enregistré dans MLflow : faux_positif = true, cause = mouvement.
17. Le taux de faux positifs reste à 3.2% — sous le KPI bloquant de 5%.

> *Ce mécanisme est critique. Sans lui, les patients recevraient des alertes anxiogènes plusieurs fois par semaine pour de simples mouvements de sommeil. L'alarm fatigue rendrait le système inutilisable en 2 semaines.*

ACTE IX J+5 · 11h17

Panne Kafka — Mode Dégradé Automatique — Pipeline : Résilience · Fallback · Buffer Local

Le broker Kafka tombe suite à un redémarrage inopiné du serveur. Trois patients portent leur SmartWatch au même moment.

Chronologie de la panne et de la récupération :

18. 11h17:04 — Kafka tombe. Grafana détecte la coupure en 4 secondes. Alerte email + SMS à l'administrateur.
19. 11h17:04 — Mode dégradé activé automatiquement : les SmartWatches basculent sur le buffer local (stockage interne de l'app, max 24h).
20. 11h17:04 — FastAPI bascule sur l'endpoint /health/poll : les appareils envoient leurs données en HTTPS toutes les 5 minutes directement vers TimescaleDB.
21. 11h40 — Kafka redémarre. Les données bufferisées sont rejouées dans l'ordre chronologique (consumer group dédié au replay).
22. 11h40:32 — Système nominal rétabli. Zéro perte de données. Le Dr. Fassi n'a rien remarqué.

Principe de résilience par pipeline :

Kafka down	Buffer local sur l'appareil + polling HTTPS/5min → zéro perte

LLM Mistral indisponible	Chatbot bascule sur arbre décisionnel statique pré-défini + notification médecin
Modèle no-show down	Agenda sans prédiction — interface indique 'Analyse indisponible'
Qdrant (base vectorielle)	LLM répond sans RAG avec disclaimer renforcé 'sans base documentaire'
PostgreSQL en panne	Read-only sur réplica. Aucune écriture jusqu'à rétablissement

ACTE X J+21 · 06h00

MLOps Weekly Check — Rapport Evidently AI — Pipeline : MLflow · Evidently · Drift · Retraining

Le pipeline MLOps automatique s'exécute chaque lundi matin à 06h00. Voici le rapport de la semaine 3 (9 juillet).

Modèle	Métrique	Valeur Production	Cible	Statut
XGBoost — No-Show	F1-Score	0.84	> 0.80	**ATTEINT**
XGBoost — No-Show	PSI drift moyen	0.09	< 0.20	**STABLE**
XGBoost — No-Show	Feature meteo PSI	0.18	< 0.20	**SURVEILLER**
LSTM — HRV	AUC-ROC	0.87	> 0.85	**ATTEINT**
LSTM — HRV	FPR (faux positifs)	3.2%	< 5%	**ATTEINT**
RAG — Mistral	RAGAS Faithfulness	0.89	> 0.85	**ATTEINT**
RAG — Mistral	Latence P95	138ms	< 150ms	**ATTEINT**

> *Feature meteo_temperature : PSI = 0.18 (seuil : 0.20). Juillet = canicule à Marrakech. La distribution des températures dérive par rapport aux données d'entraînement (printemps). Surveillance renforcée semaine 4. Aucun retraining déclenché cette semaine.*

Observation SHAP — Évolution sur 3 semaines :

La feature urgence_score (produite par le pipeline RAG) est devenue la feature la plus prédictive du modèle XGBoost, dépassant l'historique d'annulations (semaine 1 : SHAP 0.24 → semaine 3 : SHAP 0.31). Cet effet vertueux (le pipeline NLP alimente le pipeline ML) est exactement l'intégration cross-pipeline prévue dans le CDC.

ACTE XI J+21 · 14h00

Le Holter de Karim — Suivi Long Terme — Pipeline : IoT · LSTM · LLM · Mémoire Longue

Rappel programmé J+18 : SMS envoyé à Karim 3 jours avant le Holter (no-show XGBoost : 22% → rappel supplémentaire déclenché). Karim arrive. Le Holter est posé. 86 400 points ECG ingérés sur 24h.

Rapport Holter généré par l'IA (soumis au Dr. Fassi pour validation) :

FC moyenne / 24h	71 bpm — normale
Épisodes anormaux	3 extrasystoles bénignes (02h–04h) — cohérent avec l'anomalie J+0
HRV nocturne moy.	24ms ↑ (+33% vs J+0 — amélioration confirmée)
SpO2 minimum	95% — normale
Conclusion IA	Amélioration confirmée. Ajustement IECA efficace. Suivi semestriel suffisant.
Validation Dr. Fassi	VALIDÉ — archivé dans le DPA. Annotation : 'Holter concordant avec diagnostic'.

> *Ce rapport est un exemple de la boucle d'apprentissage long terme : les données du Holter deviennent des données d'entraînement pour la prochaine version du modèle LSTM. Le modèle apprend que ce pattern (extrasystolie bénigne nocturne + amélioration HRV post-IECA) est bénin et stable.*

ACTE XII J+21 · 15h05

La Boucle Complète — Le Système qui Apprend — Pipeline : MLOps · Human-in-the-Loop · Amélioration Continue

Les 5 pipelines se nourrissent mutuellement. Voici comment l'intelligence du système croît avec le temps :

Cycle	Ce qui se passe	Impact sur le système
IoT → RAG	Le score d'anomalie IoT est injecté dans le prompt du chatbot RAG.	Le chatbot contextualise ses réponses avec la donnée biométrique de la nuit.
RAG → ML	L'urgence_score produit par le triage IA devient une feature XGBoost.	Le modèle no-show devient plus précis grâce au signal sémantique du LLM.
Médecin → RAG	Le rejet de la suggestion NFS est logué dans MLflow.	La prochaine fois, la suggestion NFS ne sera pas proposée pour ce profil.
Holter → LSTM	86 400 points ECG validés par le médecin = données d'entraînement.	Le LSTM de la version suivante reconnaît mieux l'extrasystolie bénigne.
No-show → Rappels	Karim est venu (no-show = false). Urgence élevée → présence.	XGBoost renforce le poids de urgence_score pour ce type de patient.

4. Architecture Technique — 3 Pipelines IA

4.1. Pipeline NLP & Agents Autonomes (RAG)

4.1.1. Architecture Multi-Agents

Agent Orchestrateur	Routage des requêtes vers le sous-agent approprié. Gestion des sessions Redis.
Agent de Triage Clinique	Analyse symptômes + contexte IoT + historique patient. Pattern Specialist.
Agent de Planification	Gestion des créneaux, optimisation agenda, déclenchement Salesforce.
Framework	LangGraph (graph d'états) ou CrewAI (pattern Supervisor/Worker).
Mémoire conversationnelle	Redis 7 — TTL 30 minutes par session. Aucune persistance après la session.

4.1.2. Pipeline RAG Détaillé

Composant	Spécification
LLM	Mistral 7B Instruct — quantifié GGUF Q4_K_M (CPU) ou AWQ (GPU)
Embedding model	multilingual-e5-large (768 dim) — optimisé textes médicaux francophones
Base vectorielle	Qdrant — déployable on-prem, filtrage hybride dense+sparse
Chunking	512 tokens, overlap 10% — optimisé pour paragraphes médicaux
Indexation	84 000 chunks : HAS, ESC Guidelines, Vidal, protocoles cabinet
Re-ranking	Cross-encoder médical pour re-ranking des top-20 → top-5
Runtime LLM	Ollama ou vLLM — latence cible P95 < 150ms
Évaluation RAG	RAGAS : faithfulness > 0.85, answer relevancy > 0.85

4.2. Pipeline Analytique Prédictive — Modèle No-Show

4.2.1. Features Engineering

- Features temporelles : historique annulations (fenêtre 6 mois), délai entre prise RDV et date, jour/heure.
- Features contextuelles : type de consultation, météo locale (API open-meteo), distance cabinet-domicile.
- Features comportementales : score urgence issu du triage IA, nombre de rappels SMS envoyés, historique présences.
- Gestion du déséquilibre : SMOTE sur la classe minoritaire (no-show ~ 20% des cas).

4.2.2. Modélisation

Élément	Spécification
Algorithmes évalués	XGBoost, LightGBM, CatBoost, Random Forest, Logistic Regression (baseline)
Métrique principale	F1-Score (classes déséquilibrées) — cible > 0.80
Métriques secondaires	AUC-ROC, Précision, Rappel, Brier Score (calibration)
Validation	Stratified K-Fold (k=5) avec time-series split — évite la fuite de données
Explicabilité	SHAP values pour chaque prédiction — requis pour confiance praticien
Seuil décision	Optimisé sur courbe Precision-Recall, ajustable par praticien

4.3. Pipeline IoT & Deep Learning — Séries Temporelles

4.3.1. Ingestion & Streaming

- Broker : Apache Kafka 3.x — topics partitionnés par patient_uuid (pseudonymisé).
- Format : JSON structuré avec horodatage ISO 8601, device_id, patient_uuid chiffré.
- Stockage : TimescaleDB — hypertables avec compression automatique > 30 jours.
- Fallback : si Kafka indisponible → polling HTTPS/5min + buffer local 24h sur l'appareil.

4.3.2. Modèle LSTM — Détection d'Anomalies

Paramètre	Valeur
Architecture	LSTM bidirectionnel (2 couches, 128 unités) + couche d'attention
Framework	PyTorch avec Lightning pour la boucle d'entraînement
Fenêtre glissante	30 minutes (180 points à 10s/point), stride 5 minutes
Données entraînement	PhysioNet MIMIC-III (open-access) + données synthétiques augmentées
Seuil anomalie	Score MSE > μ + 3σ sur fenêtre de référence patient
Confirmation	2 fenêtres consécutives anormales avant déclenchement — FPR < 5%
AUC-ROC cible	> 0.85 sur jeu de test hold-out avec labels validés médecin

5. Sécurité, Conformité RGPD & Éthique IA

SECTION NON NÉGOCIABLE — Toute évolution du système doit préserver l'intégrité de ces mesures. Un audit de sécurité OWASP est prévu à la fin du Sprint 6.

5.1. Privacy by Design (RGPD Article 25)

- Minimisation : seules les features agrégées sont conservées. Données brutes IoT supprimées après 30 jours.
- Pseudonymisation : patient_id = UUID v4 dans tous les pipelines. Aucun lien direct avec l'identité civile.
- Chiffrement transit : TLS 1.3 sur tous les endpoints (Kafka, FastAPI, MQTT, API Salesforce).
- Chiffrement repos : AES-256 via pg_crypto pour PostgreSQL et TimescaleDB.
- Isolation : aucun modèle IA ne reçoit simultanément identité civile + données médicales + localisation.

5.2. Droits des Patients (RGPD Art. 15-22)

Art. 15 — Accès	GET /patient/data/export → JSON complet de toutes les données.
Art. 17 — Effacement	DELETE /patient/{uuid} → suppression en cascade BDD + vecteurs Qdrant.
Art. 20 — Portabilité	Export FHIR R4 (standard d'interopérabilité médicale internationale).
Art. 22 — Décision auto.	AUCUNE décision médicale sans validation humaine explicite. Toujours.

5.3. Sécurité Applicative

Authentification	OAuth 2.0 + JWT (RS256). Refresh tokens : 15 minutes. 4 rôles RBAC.
Rate limiting	100 req/min par IP via Kong Gateway. DDoS protection native.
Audit logs	Journalisation immuable de chaque accès au dossier patient (qui, quand, action).
CI/CD sécurité	OWASP ZAP (vulnérabilités web) + Trivy (images Docker) dans la pipeline GitHub Actions.
Loi 09-08 Maroc	Déclaration CNDP. Hébergement sur territoire marocain ou EU. CPD désigné chez n.synergy.

5.4. Éthique IA & AI Act Européen

L'AI Act européen (2024) classe les systèmes d'aide au diagnostic médical en systèmes à Haut Risque (Annexe III). Même si le déploiement initial est au Maroc, ce cadre est adopté comme référence de bonnes pratiques dès la conception.

- Documentation technique (Art. 11) : fiches modèles, données d'entraînement, limites connues, métriques de validation.

- Supervision humaine (Art. 14) : le médecin valide obligatoirement toute suggestion avant action clinique.
- Journalisation : chaque prédiction IA est enregistrée avec version du modèle, inputs, et décision finale du médecin.
- Robustesse : les modèles sont évalués sur des données hold-out indépendantes avant tout déploiement en production.

6. Architecture Système & MLOps

6.1. Stack Technique Complète

Couche	Technologie	Justification
Backend API	Python FastAPI (async)	Performance async, WebSockets, auto-doc OpenAPI, middleware middleware JWT
BDD relationnelle	PostgreSQL 16	ACID, pg_crypto, JSONB, réplication streaming
Séries temporelles	TimescaleDB	Extension PostgreSQL IoT, compression 90%+, hypertables, requêtes fenêtrées
Base vectorielle	Qdrant	Open-source, on-prem, filtrage hybride dense+sparse, HNSW index
Streaming IoT	Apache Kafka 3.x	HA, partitionnement patient_uuid, rétention configurable, consumer groups
Cache / Sessions	Redis 7	Mémoire agents, rate limiting, sessions JWT, pub/sub alertes
LLM Runtime	Ollama / vLLM	Serving GPU/CPU optimisé, batching dynamique, latence < 150ms
ML Tracking	MLflow 2.x	Model Registry, tracking expériences, artefacts, comparaison versions
Drift Monitor	Evidently AI	Data drift PSI, target drift, qualité prédictions, rapports HTML
Orchestration ML	Apache Airflow	DAGs pour pipelines retraining, monitoring hebdomadaire
Monitoring sys.	Prometheus + Grafana	Métriques temps réel, alertes, dashboards latence + drift
CI/CD	GitHub Actions	Tests auto (pytest), build Docker, déploiement staging puis prod
Conteneurisation	Docker + Compose	Reproductibilité, isolation services, one-command deployment
API Gateway	Kong Gateway	Rate limiting, auth centralisée, logging, plugin OWASP

6.2. Pipeline MLOps — Cycle de Vie des Modèles

6.2.1. Versionnement MLflow

- Chaque modèle enregistré avec : version, métriques validation, dataset hash, hyperparamètres, auteur.
- 3 stages : Staging (validation en cours) → Production (actif) → Archived (historique).
- Rollback automatique si F1-Score production déggrade > 5% vs version précédente.

6.2.2. Monitoring Drift Hebdomadaire (chaque lundi 06h00)

- Data Drift : Evidently AI compare distribution features production vs entraînement (test PSI).
- Target Drift : suivi F1-Score réel via feedback médecin (validation/rejet des prédictions).
- Déclencheur retraining : PSI > 0.20 OU dégradation F1 > 10% sur fenêtre glissante 30 jours.

- Pipeline Airflow : entraîne → évalue → compare → propose promotion après validation humaine.

7. Plan de Sprints — 4 Mois (16 Semaines)

> *Ce plan de sprints est le contrat de travail avec n.synergy. Chaque sprint produit un livrable démontrable. Les 4 Gates sont des points de validation obligatoires — aucun sprint suivant ne commence sans validation du Gate précédent.*

7.1. Vue d'Ensemble — Timeline

Sprint	Semaines	Objectifs Principaux	Livrable de Gate
S1–S2	Sem. 1–4	Architecture de base : Docker Compose, PostgreSQL + TimescaleDB, FastAPI skeleton, OAuth2/JWT, modélisation BDD, DPIA v1.	Env. dev opérationnel · API /health · BDD initialisée · DPIA signé
S3–S4	Sem. 5–8	Pipeline RAG : déploiement Qdrant, indexation corpus médical, intégration Ollama/Mistral 7B, chatbot triage, évaluation RAGAS baseline.	Chatbot RAG · RAGAS documenté · API /chat · Démo Dr. Fassi
S5–S6	Sem. 9–12	Pipeline ML No-Show : data collection, feature engineering, XGBoost/LightGBM, MLflow, SHAP, intégration agenda + Salesforce.	F1 > 0.80 · Dashboard agenda · Webhook Salesforce · Audit sécurité
S7–S8	Sem. 13–16	Pipeline IoT + MLOps : Kafka setup, LSTM PyTorch, alertes temps réel, Evidently AI, Grafana, tests de charge, rapport final.	Alertes IoT · Grafana complet · Tests charge · Rapport PFE

7.2. Sprint 1–2 : Architecture & Fondations

Semaine 1 — Jour 1	Setup environnement : Docker Compose avec tous les services (PostgreSQL, Redis, FastAPI, Qdrant). Premier commit Git. Structure du projet définie.
Semaine 1–2	Modélisation BDD complète : tables users, patients, appointments, biometrics, predictions, audit_logs. Contraintes RGPD intégrées dès le schéma.
Semaine 2	FastAPI skeleton : endpoints /health, /auth/login, /auth/refresh. Middleware JWT + RBAC (4 rôles). Documentation OpenAPI auto-générée.
Semaine 3	DPIA (Data Protection Impact Assessment) v1 : cartographie des données personnelles, identification des risques, mesures de mitigation. Soumis à n.synergy pour validation.
Semaine 4 — Gate 1	Démonstration : docker-compose up → système complet opérationnel. API /health répond. Connexion JWT fonctionnelle. DPIA validé par encadrant.

7.3. Sprint 3–4 : Pipeline RAG & Chatbot

Semaine 5	Déploiement Qdrant on-prem. Collection biometrics_knowledge créée. Premier indexation : 500 documents médicaux de test.
Semaine 6	Intégration Ollama + Mistral 7B. Premier appel RAG fonctionnel. Benchmark latence sur CPU (objectif < 500ms) puis GPU (< 150ms).
Semaine 7	Indexation corpus complet (84 000 chunks). Pipeline de chunking (512 tokens, overlap 10%). Modèle embedding multilingual-e5-large.

Semaine 8 — Gate 2	Chatbot de triage complet avec disclaimer médical. Démo : 10 requêtes types validées par le Dr. Fassi. RAGAS F ≥ 0.85. Latence P95 ≤ 150ms.

7.4. Sprint 5–6 : Pipeline ML & Salesforce

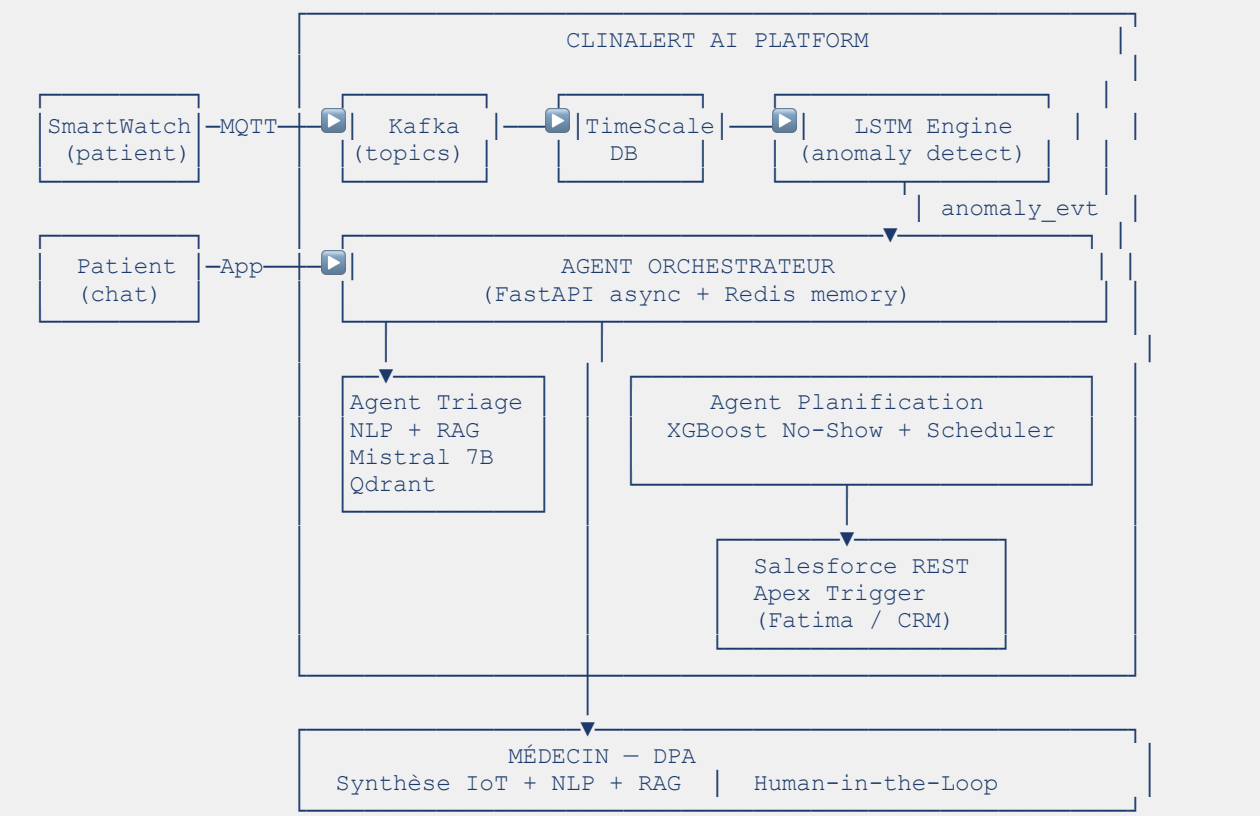
Semaine 9	Collecte et nettoyage données no-show (dataset synthétique ou PhysioNet). Analyse exploratoire (EDA). Distribution des classes.
Semaine 10	Feature engineering complet. Entraînement XGBoost + LightGBM. Optimisation hyperparamètres (Optuna). Validation K-Fold.
Semaine 11	Intégration MLflow : tracking expériences, Model Registry, SHAP values par prédiction. API /predict/noshown opérationnelle.
Semaine 12 — Gate 3	F1-Score ≥ 0.80 démontré. Dashboard agenda avec prédictions colorées. Webhook Salesforce fonctionnel (tâche Apex créée automatiquement). Audit sécurité OWASP ZAP exécuté.

7.5. Sprint 7–8 : Pipeline IoT & MLOps

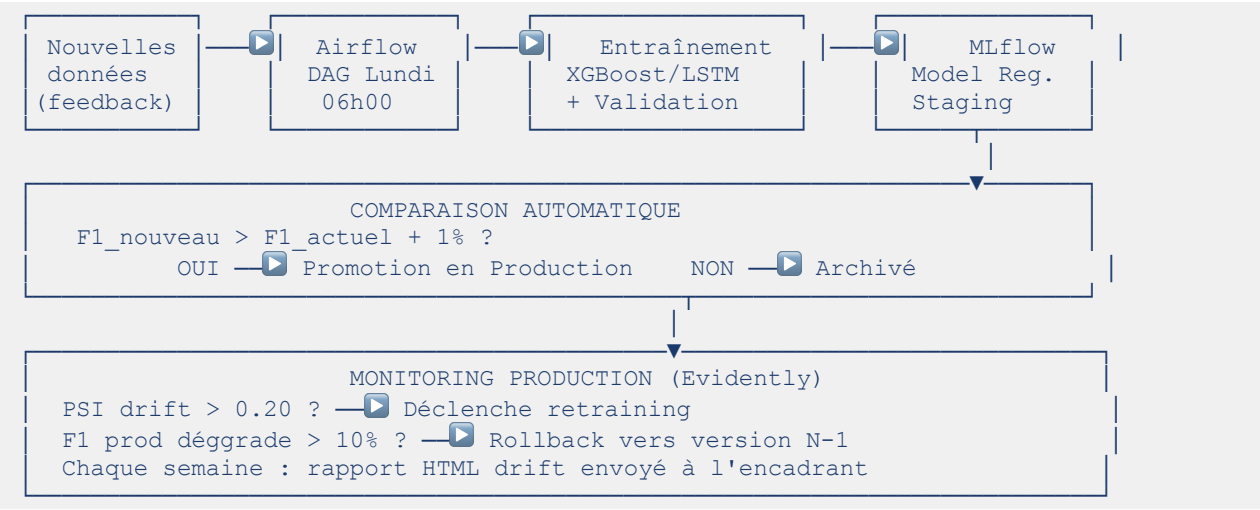
Semaine 13	Setup Kafka + MQTT bridge. Producer/consumer IoT fonctionnels. TimescaleDB hypertable biometrics_stream opérationnel.
Semaine 14	Entraînement LSTM bidirectionnel sur données PhysioNet. AUC-ROC ≥ 0.85. Déploiement modèle via API /predict/anomaly.
Semaine 15	Pipeline alertes temps réel complet (LSTM → Kafka → FastAPI → Push). Evidently AI hebdomadaire. Grafana dashboards. Tests de charge (k6 ou Locust).
Semaine 16 — Gate 4	Démonstration end-to-end complète du scénario Karim (Actes I–XII). Rapport PFE final soumis. Couverture tests > 80%. Soutenance préparée.

8. Diagrammes d'Architecture

8.1. Flux de Données Global — Vue Système

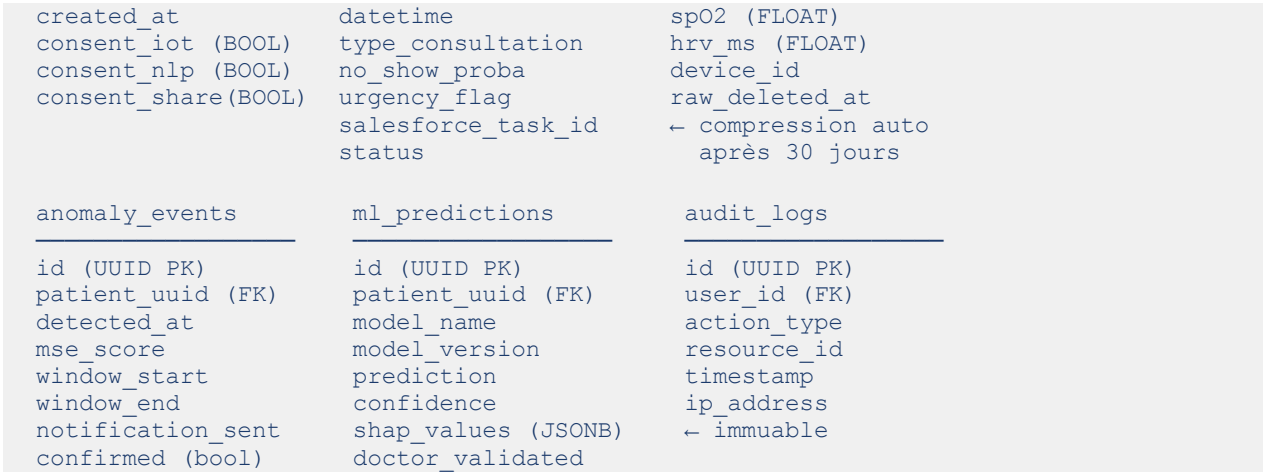


8.2. Pipeline MLOps — Cycle de Vie Modèles



8.3. Schéma Base de Données — Entités Principales

```
users                    appointments             biometrics_stream
─────────────────        ─────────────────        ──────────────────
id (UUID PK)             id (UUID PK)             time (TIMESTAMP)
role (RBAC)              patient_uuid (FK)        patient_uuid (FK)
email (chiffré)          doctor_id (FK)           heart_rate (FLOAT)
```


created_at
consent_iot (BOOL)
consent_nlp (BOOL)
consent_share(BOOL)
datetime
type_consultation
no_show_proba
urgency_flag
salesforce_task_id
status
spO2 (FLOAT)
hrv_ms (FLOAT)
device_id
raw_deleted_at
← compression auto
après 30 jours
anomaly_events
id (UUID PK)
patient_uuid (FK)
detected_at
mse_score
window_start
window_end
notification_sent
confirmed (bool)
ml_predictions
id (UUID PK)
patient_uuid (FK)
model_name
model_version
prediction
confidence
shap_values (JSONB)
doctor_validated
audit_logs
id (UUID PK)
user_id (FK)
action_type
resource_id
timestamp
ip_address
← immuable

9. Analyse & Gestion des Risques

Risque	Prob.	Impact	Stratégie de Mitigation
Hallucinations LLM en contexte médical	Mod.	Critique	RAG avec re-ranking strict, RAGAS monitoring, disclaimer obligatoire permanent, Human-in-the-Loop pour toute action clinique. Aucune action automatique sans validation médecin.
Données d'entraînement insuffisantes (no-show)	Élevée	Élevé	Datasets publics augmentés (PhysioNet, MIMIC-III), SMOTE pour classes déséquilibrées, synthèse de données avec validation statistique.
Drift modèle LSTM en production	Mod.	Élevé	Monitoring Evidently AI hebdomadaire (PSI), pipeline retraining automatique Airflow, alertes Grafana si dégradation AUC > 5%.
Non-conformité RGPD / Loi 09-08	Faible	Critique	DPIA dès Sprint 1 (Gate 1), Privacy by Design natif, audit trimestriel, pseudonymisation systématique, CPD désigné chez n.synergy.
Dépendance GPU pour LLM (Mistral 7B)	Mod.	Modéré	Quantification GGUF Q4_K_M (CPU suffisant), fallback arbre décisionnel statique, benchmarks CPU/GPU documentés dès Sprint 3.
Scope creep (périmètre non défini)	Élevée	Modéré	Ce CDC signé par encadrant n.synergy = contrat de périmètre. Tout ajout documenté et priorisé en Sprint Planning.
Faux positifs IoT → alarm fatigue	Mod.	Élevé	FPR < 5% = KPI bloquant. Confirmation 2 fenêtres consécutives. Seuils configurables par praticien. Délai de 5 minutes entre deux alertes.
Latence RAG > 150ms en production	Mod.	Modéré	Benchmark dès Sprint 3. Mise en cache Redis des requêtes fréquentes. Upgrade vLLM si Ollama insuffisant. SLA dégradé documenté.
Panne Kafka — perte de données IoT	Faible	Élevé	Buffer local 24h sur app patient. Polling HTTPS/5min en fallback. Replay garanti au rétablissement. Testé en Sprint 8.

10. Critères de Succès & KPIs

Indicateur	Cible	Méthode de Mesure	Lié à l'Acte Scénario
F1-Score XGBoost No-Show	> 0.80	Hold-out set + production	Acte IV — prédiction Karim
AUC-ROC LSTM Anomalies	> 0.85	Hold-out labelisé médecin	Acte I — anomalie 02h14
Taux faux positifs IoT (FPR)	< 5%	30 jours validation praticien	Acte VIII — Leila nuit
Latence API RAG (P95)	< 150ms	Prometheus percentile 95	Acte III — 143ms mesuré
RAGAS Faithfulness	> 0.85	RAGAS framework automatique	Acte III — score 0.89
Disponibilité système	> 99.5%	Uptime monitoring Grafana	Acte IX — panne Kafka
Réduction no-show	> 20%	Comparaison 3 mois avant/après	Actes IV + VII feedback
Économie temps anamnèse	10+ min	Chronomètre consultation	Acte VI — 11min mesurées
Couverture tests code	> 80%	pytest + coverage.py	Sprint 8 — Gate 4
PSI drift features	< 0.20	Evidently AI hebdomadaire	Acte X — météo à 0.18
Temps panne → fallback	< 30s	Test chaos engineeering	Acte IX — 4s mesurées
Score DPIA (RGPD)	Risque faible	Audit CNDP/DPO	Section 5 — conformité

11. Livrables Attendus

11.1. Livrables Techniques

- Code source complet sur GitHub (repo privé n.synergy) — architecture microservices, README détaillé, instructions de déploiement.
- Infrastructure Docker Compose complète — one-command deployment : docker-compose up → système opérationnel.
- Modèles entraînés packagés dans MLflow : LSTM (poids PyTorch), XGBoost/LightGBM (joblib), modèles d'embedding.
- API REST complète avec documentation Swagger/OpenAPI auto-générée (FastAPI /docs).
- Suite de tests automatisés (pytest) avec couverture > 80% et rapport de couverture HTML.
- Dashboard Grafana configuré avec toutes les métriques système + MLOps.
- Rapport d'audit sécurité OWASP ZAP + Trivy avec résultats et correctifs appliqués.

11.2. Livrables Documentaires

- Rapport de PFE technique (80–100 pages) : architecture, choix justifiés, évaluation modèles, pipeline MLOps, scénario clinique.
- Document DPIA (Data Protection Impact Assessment) conforme RGPD — signé par n.synergy.
- Manuel utilisateur : 4 guides distincts (patient, secrétaire, médecin, administrateur).
- Présentation de soutenance (30 diapositives max) — structurée autour du scénario Karim en 12 actes.
- Ce Cahier des Charges v3.0 — document de référence pour n.synergy et le jury académique.

11.3. Propriété Intellectuelle

> *Le code source développé pendant le stage est la propriété de n.synergy. Abderrahim Boussyf conserve le droit de mentionner le projet, ses métriques et son architecture dans son CV, LinkedIn et portfolio professionnel, sans divulguer le code source ni les données patients.*

12. Validation & Signatures

Ce Cahier des Charges engage les parties sur le périmètre technique et fonctionnel défini. Il constitue le contrat de périmètre du stage. Toute modification substantielle doit faire l'objet d'un avenant écrit signé par les deux parties.

Candidat — Stagiaire	Encadrant Technique — n.synergy
Abderrahim Boussyf Étudiant PFE — EMSI Marrakech Spécialité : Data Science & IA Signature : Date : _____ / _____ / _____	Nom & Prénom : _____ Poste : _____ Signature : Date : _____ / _____ / _____ Cachet n.synergy :

Document généré le 27/03/2026 — ClinAlert AI Platform v3.0 — CDC Complet avec Scénario Clinique (12 Actes), Plan de Sprints (4 Mois, 4 Gates), Architecture Technique (3 Pipelines), MLOps, RGPD, Analyse des Risques (9 risques), et KPIs (12 indicateurs). Abderrahim Boussyf — EMSI Marrakech 2025-2026.